

Méthodes d'appariement

Atelier Mapme : Evaluation d'impact sur données spatiales

Florent Bédécarrats, Melvin Wong (sur une base élaborée
par Jeanne de Montalembert et Marin Ferry)


Agenda



■ **1. Méthodes d'appariement:
Mais pourquoi ?**

■ **2. Méthodes d'appariement**

■ **3. Propensity Score Matching**



MÉTHODES D'APPARIEMENT: MAIS POURQUOI?



Inférence causale sans randomisation

Le problème

Les **essais contrôlés randomisés (ECR)** sont considérés comme la **référence absolue** de l'inférence causale. Dans de nombreuses disciplines: économie, épidémiologie, conservation, sciences politiques. Ils restent **toutefois impossibles à mettre en œuvre** pour des raisons éthiques, logistiques ou politiques.

Biais de sélection

Dans les études d'observation, le traitement n'est pas attribué aléatoirement. Les **groupes traité et contrôle diffèrent systématiquement** sur des caractéristiques observées et non observées — les comparaisons naïves des moyennes sont biaisées.



Example: Aire Protégée

Est-ce que le statut d'Aire Protégée a un impact sur le couvert forestier ?

C'est-à-dire :

$$E[CF1|AP = 1] - E[CF0|AP = 1]$$

avec $CF1$ le couvert forestier d'une zone si c'est une AP et $CF0$ le couvert forestier si ce n'est pas une AP, **pour la même zone et au même moment.**

...

Le problème évident est qu'on n'observe jamais simultanément les deux états pour la même unité. On a déjà vu le problème: $E[Y0_i|T_i = 1]$ n'est pas observable.

...

-
-

Le problème contrefactuel

T r a i t é

$Y(1)$ observé

$Y(0)$ inconnu

C o n t r o l l e

$Y(0)$ observé

$Y(1)$ inconnu

Les sciences naturelles échappent à ce problème



La solution expérimentale

En laboratoire, le chercheur **contrôle entièrement l'attribution du traitement**. Il observe un état de référence **Y(0)** — l'unité sans traitement — puis l'état traité **Y(1)**.

Les unités sont **identiques au départ**, il n'y a aucun biais de sélection : la différence observée est l'effet causal.



Y(0) — témoin
(sans bactéries)



Y(1) — traité (avec
bactéries)



Example: Aire Protégée

Est-ce que le statut d'Aire Protégée a un impact sur le couvert forestier ?

C'est-à-dire :

$$E[CF1|AP = 1] - E[CF0|AP = 1]$$

avec $CF1$ le couvert forestier d'une zone si c'est une AP et $CF0$ le couvert forestier si ce n'est pas une AP, **pour la même zone et au même moment.**

...

Le problème évident est qu'on n'observe jamais simultanément les deux états pour la même unité. On a déjà vu le problème: $E[Y0_i|T_i = 1]$ n'est pas observable.

...

⇒ Quel contrefactuel utiliser ?

- Comparer des zones différentes ?
- Risque de confusion avec des effets structurels.

Le problème contrefactuel

T r a i t é

$Y(1)$ observé

$Y(0)$ inconnu

C o n t r o l l e

$Y(0)$ observé

$Y(1)$ inconnu



Illustration intuitive

Comparaison naïve entre deux zones :

Zone	Couvert forestier observé
Makira	$CF_M = M + AP$
Autre	$CF_A = A$

Remarque :

M = caractéristiques propres à Makira (relief, climat, accès...)

A = caractéristiques propres à la zone non protégée

AP = effet de l'aire protégée

Différence observée :

$$CF_M - CF_A = (M + AP) - A = \Delta$$

- **Problème :**
On voudrait isoler **AP**,
mais on capte aussi **(M-A)**.
- **Biais de sélection** dû aux
différences structurelles entre
zones.
- L'appariement vise à trouver une
zone non protégée où **M ≈ A**.


Principe du matching

On cherche une zone non traitée **qui ressemble le plus possible** à la zone traitée : son “jumeau”.

L'idée est de comparer les résultats entre unités aux caractéristiques observables X proches, en supposant que **toute la sélection dans le traitement passe par X** .

Le matching est effectivement une méthode pour couper/elaguer des données. on écarte les observations sans jumeau.

Anglais: „pruning“






Hypothèses fondamentales

- $E[Y0_i|T_i = 1] = E[Y0_i|T_i = 0]$
 - $E[Y0_i|T_i = 1]$ n'existe pas
 - $E[Y0_i|T_i = 0]$ exist mais doit satisfaire à deux conditions.
- **Indépendance conditionnelle (CIA) :**
 - $(Y(1), Y(0)) \perp T \mid X$
 $\Rightarrow$ À caractéristiques observables identiques, l'assignation est as-if aléatoire.
- **Support commun (overlap) :**
Pour chaque X , il existe des unités traitées et non traitées.

Risques liés à la CIA

- La CIA suppose qu'aucune variable inobservée ne détermine à la fois T et Y .




Hypothèse de support commun


On suppose qu'il existe, pour chaque valeur de X , des unités traitées et non traitées.

Sinon, impossible de construire un groupe de comparaison.

Vérification graphique et exclusion des zones hors support.

⇒ Il faut des jumeaux **observables** et **non systématiquement traités**.





METHODES D'APPARIEMENT (A.K.A. ELAGUER LES DONNÉS)






Méthodes d'appariement — illustration

Exact

X identiques


Traités

Contrôles




Coarsened-Exact

Exact après discrétisation




Nearest-Neighbor

Plus proche voisin




Optimal

Distance totale minimisée




Full

Toutes les unités, poids variables



Noyau

Poids décroissants (fenêtre h)




Mesures de distance pour définir “le plus proche”



Distance euclidienne


$$\sqrt{\sum (x_i - y_i)^2}$$



simple somme des différences;
calcule via le théorème de Pythagore

Distance de Mahalanobis


$$\sqrt{(x-y)^T \Sigma^{-1} (x-y)}$$



compte de la variance et des
corrélations entre covariables

Score de propension

$$p(X) = P(T=1 \mid X)$$



probabilité d'être traité
conditionnellement à X



Voisin le plus proche

- Méthode intuitive : on apparie chaque unité traitée avec sa plus proche unité contrôle.
- On peut apparier avec un seul jumeau ou avec m plus proches voisins.
- On peut aussi exclure les paires trop éloignées en fixant un seuil de distance (*caliper*).

⇒ La méthode est simple, mais la qualité de l'appariement dépend directement de la façon de mesurer la proximité.

Appariement avec ou sans remise

Définitions



- **Sans remise** : chaque unité de contrôle est utilisée au plus une fois.
- **Avec remise** : un même contrôle peut être réutilisé pour plusieurs traitements.

Avantage — avec remise

- Plus de flexibilité et meilleure qualité des appariements dans les petits échantillons. Mais forte dépendance d'un petit nombre d'unités

Inconvénients — sans remise

- Nécessite un large échantillon de contrôle.
- Estimation sensible à l'ordre d'appariement.





Limites du plus proche voisin

- L'appariement avec le voisin plus proche est assez simple à mettre en œuvre.
- Son principe est intuitif et ne demande pas de choix de paramètres très lourds.

Toutefois :

- unité la plus proche $\neq$ unité vraiment proche ;
- certains plus proches voisins peuvent rester assez éloignés ;
- la méthode traite de la même manière des couples très proches et moins proches ;
- apparier avec un seul contrôle prive de l'information apportée par les autres unités comparables.


⇒ Biais possible et perte de précision.

Biais vs variance — illustration




Chaque méthode a des avantages et des inconvénients.

L'opposition entre la plus simple (voisin le plus proche) et la plus élaborée (noyau) reflète le dilemme classique entre biais et variance.



En pratique : tester la sensibilité des résultats au choix de la méthode.



PROPENSITY SCORE MATCHING

Curse of dimensionality



Le matching exact est souvent compliqué à mettre en œuvre.

Pour que l'hypothèse CIA soit vérifiée, on souhaite utiliser le maximum d'information et donc apparier sur de très nombreuses variables. Mais plus on intègre des variables, plus il s'avérera difficile de trouver un voisin proche.


À distance finie, les estimateurs sont d'autant plus biaisés que le nombre de variables de conditionnement X est élevé (d'autant plus lorsque les variables de conditionnement sont continues).

⇒ L'appariement sur le score de propension (PSM) est pragmatique et désirable.


Score de propension : réduction de dimension



Covariables multiples



Réduction
de
dimension




Appariement



Comparaison appariée

Traités

Non traités



appariés sur le même $\pi(X)$

Hypothèse CIA (Rosenbaum & Rubin, 1983) : conditionnellement au score,

$$(Y(0), Y(1)) \perp T \mid \pi(X)$$

Remarque: $(Y(0), Y(1)) \perp T \mid X \Rightarrow (Y(0), Y(1)) \perp T \mid \pi(X_i)$ diminue le nombre de dimensions / résumé univarié de l'ensemble des covariables.

II · THÉORIE

Le score de propension (Rosenbaum & Rubin, 1983)

Définition

$$\pi(X_i) = P(T_i = 1 \mid X_i)$$

Probabilité conditionnelle de recevoir le traitement, étant donné le vecteur des covariables observées X .

Propriété d'équilibrage

Conditionnellement au score de propension, les covariables observées sont équilibrées entre groupes traité et témoin : $X \perp T \mid e(X)$.

Réduction de dimension

Au lieu d'un conditionnement de haute dimension sur X , il suffit de conditionner sur le score scalaire $e(X)$ — l'innovation centrale de Rosenbaum & Rubin.

Rosenbaum, P. R. & Rubin, D. B. (1983). The Central Role of the Propensity Score in Observational Studies for Causal Effects. *Biometrika*, 70(1), 41–55.

Estimation du score de propension



Pour tenir compte de la nature bornée du PSM, il est d'usage de le modéliser par une forme logistique (ou un probit) :

$$\pi(X_i) = P(T_i = 1 \mid X_i)$$

Même s'il est coutume d'estimer le PSM par un modèle logit ou probit, il convient de se rappeler que la forme fonctionnelle du PSM est souvent inconnue.

Vérification du support commun



Les méthodes présentées sous l'hypothèse d'indépendance conditionnelle reposent sur l'hypothèse d'un support commun.

Celle-ci signifie qu'il existe à la fois des unités traitées et des non traitées ayant des valeurs des observables identiques, i.e. qui partagent le même PSM.

Si ce n'est pas le cas, il sera impossible de trouver pour chaque unité traitée des non traitées comparables.

⇒ Il est important de vérifier que le support commun est suffisamment large.

Test visuel du support commun



On peut représenter le support commun à partir de la distribution des scores de propension des unités traitées et non-traitées.

En pratique, on représente les histogrammes de probabilité estimée d'être traité pour les unités bénéficiaires et des non bénéficiaires du traitement étudié.

On peut ensuite vérifier l'étendue des valeurs de $\pi(X_i)$ pour lesquelles on observe un nombre suffisant d'unités traitées et non-traitées, i.e. la largeur du support commun.

Test visuel du support commun




Figure 1: Exemple de support commun

Enjeux liés au support commun




Figure 2: Exemple de support commun et validité externe

Imposer un support commun



Méthode du min/max

- Pour estimer l'ATT, Dehejia et Wahba (1999) proposent d'éliminer :
 1. les unités non traitées ayant un score inférieur au minimum observé sur les unités traitées, c.à.d. *"Jamais traités"*
 2. les unités traitées ayant un score supérieur au maximum observé pour les unités non traitées, c.à.d *"always treated"*

Attention : Ce qui est alors estimé, ce n'est plus un *ATE* (average treatment effect), ni même un *ATT* (average treatment effect on the treated) mais un *ATM* (average treatment effect on the matched observations)

Quelles variables de conditionnement/contrôle ?



L'hypothèse d'indépendance conditionnelle demande d'observer les caractéristiques qui déterminent l'allocation du traitement.

En pratique, il doit s'agir de variables qui peuvent avoir un impact sur la variable d'intérêt (e.g. déforestation) et sur le choix de bénéficier du dispositif (e.g. Aire Protégée).

Deux points de vigilance : - Il ne faut pas utiliser de variables mesurées après la mise en place du dispositif et qui peuvent également affecter celui-ci → problème d'endogénéité - Il faut qu'il existe une part d'aléa ou d'exogénéité dans la sélection des unités traitées sinon il n'y a plus de support commun puisque la participation au programme est entièrement déterminée par des caractéristiques des unités.

Estimateur



L'effet moyen estimé sur les traités correspond à la moyenne de ces effets estimés :

$$\hat{E}[Y_i(1) - Y_i(0)|T_i = 1] = \frac{1}{n_1} \sum_{i \in E_1}^n (y_i(1) - \hat{y}_i(0))$$

où :

- n_1 est le nombre d'unités traitées
- E_1 est l'ensemble des unités traitées
- $y_i(1)$ le résultat observé de l'individu i
- $\hat{y}_i(0)$ le résultat du plus proche voisin non traité de i

Résumé

Pour mettre en œuvre une méthode d'appariement, il faut :

- Identifier les unités traitées et les non-traitées
- Observer les caractéristiques qui déterminent le traitement pour chaque unité
- Choisir une méthode d'estimation : plus proche(s) voisin(s), PSM ?
- Dans le cas d'un appariement sur le score de propension, il faut l'estimer
- Estimer les effets (ATT et/ou ATE)

Résumé

La crédibilité des estimateurs estimés repose sur l'hypothèse très forte d'indépendance conditionnelle.

- Tiens aux observables **disponibles et utilisées** pour la comparaison
- Si on dispose de peu d'informations dans nos données sur les choix entre les variables, il ne sera pas possible d'éliminer le **biais de sélection**